# Inteligência Artificial



## **Deep Learning**

Professor. Dr. Rogério de Oliveira

TURMA 01A - MATRÍCULA 92104843 Fernando Antonio Carvalho Pessoa

Tarefa da trilha 4: Modelos Sequenciais e Classificação com Keras TensorFlow

## Introdução

Nesta tarefa devemos implementar um modelo de classificação binária ou multiclasse para um conjunto de dados TensorFlow e o Keras.

#### Dataset

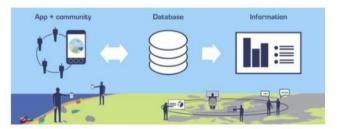
O dataset escolhido é o MLW\_Data, este dataset fornecido pela Agência Europeia de Ambiente, é criado a partir de um aplicativo denominado LitterWatch, que é utilizado nas comunidades costeiras da Europa para identificar o lixo jogado ao oceano.

#### Fonte da base

https://www.eea.europa.eu/data-and-maps/data/marine-litter

#### Visualização por TABLEAU

 $\underline{https://www.eea.europa.eu/themes/water/europes-seas-and-coasts/assessments/marine-litterwatch/data-and-results/marine-litterwatch/data$ data-viewer/marine-litterwatch-data-viewer



## Objetivo do modelo

Tendo o levantamento do lixo, por tipo e quantidade, localizado em cada comunidade, nosso objetivo é treinar o modelo para identificar e categorizar o local como POLUIDO ou LIMPO

## Importando Bibliotecas

- import pandas as pd
  - from IPython.display import display
  - import seaborn as sns

  - import numpy as np from tensorflow import keras from tensorflow.keras import layers
  - import tensorflow as tf

## Importando datasets

Carregando os dados coletados no aplicativo e a tabela de categorias de lixo

### Base de dados do agrupamento por tipo de lixo

```
[2] 1 # carregando dados de agrupamento para o Google Colab
           from google.colab import files
       3 uploaded = files.upload()
               r arquivos MLW_Meta.csv

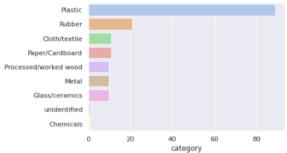
    MLW_Meta.csv(application/vnd.ms-excel) - 6826 bytes, last modified: 06/09/2021 - 100% done

     Saving MLW_Meta.csv to MLW_Meta.csv
[3] 1 # Carregando o arquivo CSV em dataframe
      2 Titulos = pd.read_csv('/content/MLW_Meta.csv', engine= 'python', sep = ';', encoding='utf-8')
[4] 1 #Analise da quantidade de colunas e linhas
    2 Titulos.shape
     (164, 3)
[5] 1 Titulos.info()
     <class 'pandas.core.frame.DataFrame'>
RangeIndex: 164 entries, 0 to 163
Data columns (total 3 columns):
      # Column
                         Non-Null Count Dtype
      0 generalcode 164 non-null
1 category 164 non-null
2 generalname 164 non-null
                                             object
                                             object
                                            object
     dtypes: object(3)
memory usage: 4.0+ KB
[6] 1 Titulos.head(10)
         generalcode category
                                                                      generalname
      0
                   G1
                            Plastic
                                                       4/6-pack yokes, six-pack rings
      1
                   G3
                            Plastic
                                                         Shopping Bags incl. pieces
      2
                   G4
                           Plastic
                                        Small plastic bags, e.g. freezer bags incl. pi...
      3
                   G5
                            Plastic
                                     Plastic bags collective role what remains from...
      4
                   G7
                            Plastic
                                                                Drink bottles <= 0.5l
```

```
5
             G8
                      Plastic
                                                            Drink bottles >0.5l
6
             G9
                     Plastic
                                                  Cleaner bottles & containers
7
            G10
                      Plastic
                                      Food containers incl. fast food containers
8
            G11
                     Plastic Beach use related cosmetic bottles and contain...
9
            G12
                      Plastic
                                          Other cosmetics bottles & containers
```

```
[7] 1 Titulos.groupby('category')['category'].count()
```

```
category
Chemicals
Cloth/textile
Glass/ceramics
                          10
Metal
Paper/Cardboard
                           10
Plastic
                           89
Processed/worked wood
Rubber
                           10
unidentified
Name: category, dtype: int64
```



## Base de dados da pesquisa

```
# carregando o arquivo dados para o Google Colab
[9]
            from google.colab import files
            uploaded = files.upload()
      Escolher arquivos MLW_Data.csv

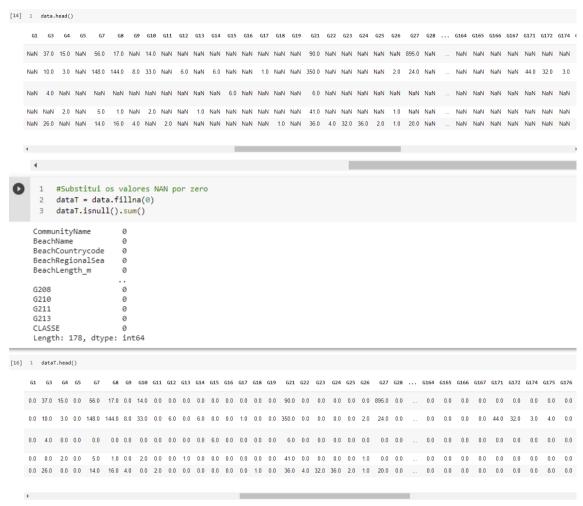
    MLW Data.csv(application/vnd.ms-excel) - 100156 bytes, last modified: 06/09/2021 - 100% done

      Saving MLW_Data.csv to MLW_Data.csv
[10] 1 data = pd.read_csv('/content/MLW_Data.csv', engine= 'python', sep = ';', encoding='latin-1')
[11] 1 data.shape
      (254, 178)
[12] 1 data.head(5)
                                                                                 Other (mixed) 20160424.0 Cleanup NaN 17.619.790.849.047.900 4.291.792.327.340.360 17.607.699
                                                              1551.0
                                                                                 Other (mixed) 20160519.0 Cleanup NaN 1.910.840.665.135.820 44.368.655.173.785.800 19.109.083
          aBasPxAZ
                                                  NaN
                                                               86.0
                                                                          Urban
          Surfrider
Foundation
Europe Blakenberg
beach
                                                                         Urban
                                                                                  Sandy 20160812.0 Cleanup NaN 29.747.061.142.684.500 51.255.998.063.635.000 29.755.869
                                                                                                           NaN 2.770.921.843.173.200 42.367.082.331.608.300 2.770.950
    4 gBqsPxAZ alepu BG Black Sea 2779.0 Urban Sandy 20160313.0 Cleanup NaN 27.722.467.974.911.600 4.234.864.091.261.680 2.771.062
    5 rows × 178 columns
```

#### Pré processamento da base

O objetivo desta etapa é tratar, preparar e montar os dados coletados em uma base para aplicação do algoritmo Keras - TensorFlow

```
1 #Verifica valores NAN
 2 data.isnull().sum()
CommunityName
BeachName
BeachCountrycode
BeachRegionalSea
BeachLength_m
                     1
6208
                   147
G210
                   216
G211
                   208
G213
                   235
CLASSE
Length: 178, dtype: int64
```



### Preparando os Dados

As colunas que precisamos são os indicadores de poluição (coluna G1 a G213) e a coluna de atributo Poluido = 1 não poluido = 0

Também necessitamos susbtituir as quantidades das colunas G1 a g213 por atributo do tipo de poluente encontrado=1 ou não encontrado=0

#### Eliminando colunas

```
17 dataT1 = dataT.drop(columns=['CommunityName', 'BeachName', 'BeachNa
```

Substituição das quantidades do tipo de lixo para localizado=1 não localizado=0

```
dataT1.loc[dataT1.G1>1, 'G1']=1
1
                                               dataT1.loc[dataT1.G44>1,'G44']=1
2
    dataT1.loc[dataT1.G3>1,'G3']=1
                                               dataT1.loc[dataT1.G45>1,'G45']=1
                                          40
3
    dataT1.loc[dataT1.G4>1,'G4']=1
                                          41
                                               dataT1.loc[dataT1.G46>1, 'G46']=1
    dataT1.loc[dataT1.G5>1,'G5']=1
4
                                          42
                                               dataT1.loc[dataT1.G47>1,'G47']=1
5
    dataT1.loc[dataT1.G7>1,'G7']=1
                                               dataT1.loc[dataT1.G49>1,'G49']=1
                                          43
6
    dataT1.loc[dataT1.G8>1,'G8']=1
                                          44
                                               dataT1.loc[dataT1.G50>1,'G50']=1
7
    dataT1.loc[dataT1.G9>1, 'G9']=1
                                          45
                                               dataT1.loc[dataT1.G52>1, 'G52']=1
    dataT1.loc[dataT1.G10>1, 'G10']=1
2
                                               dataT1.loc[dataT1.G53>1, 'G53']=1
    dataT1.loc[dataT1.G11>1,'G11']=1
9
                                               dataT1.loc[dataT1.G54>1,'G54']=1
                                          47
    dataT1.loc[dataT1.G12>1, 'G12']=1
10
                                          48
                                               dataT1.loc[dataT1.G56>1, 'G56']=1
11
    dataT1.loc[dataT1.G13>1, 'G13']=1
                                          49
                                               dataT1.loc[dataT1.G57>1, 'G57']=1
12
    dataT1.loc[dataT1.G14>1, 'G14']=1
                                               dataT1.loc[dataT1.G58>1, 'G58']=1
                                          50
13
    dataT1.loc[dataT1.G15>1, 'G15']=1
                                               dataT1.loc[dataT1.G59>1,'G59']=1
    dataT1.loc[dataT1.G16>1, 'G16']=1
14
                                          52
                                               dataT1.loc[dataT1.G60>1, 'G60']=1
    dataT1.loc[dataT1.G17>1, 'G17']=1
15
                                          53
                                               dataT1.loc[dataT1.G62>1, 'G62']=1
    dataT1.loc[dataT1.G18>1, 'G18']=1
16
                                               dataT1.loc[dataT1.G63>1,'G63']=1
                                          54
17
    dataT1.loc[dataT1.G19>1, 'G19']=1
                                          55
                                               dataT1.loc[dataT1.G64>1,'G64']=1
18
    dataT1.loc[dataT1.G21>1, 'G21']=1
                                          56
                                               dataT1.loc[dataT1.G65>1,'G65']=1
19
    dataT1.loc[dataT1.G22>1, 'G22']=1
                                               dataT1.loc[dataT1.G66>1,'G66']=1
                                          57
    dataT1.loc[dataT1.G23>1, 'G23']=1
20
                                          58
                                               dataT1.loc[dataT1.G67>1,'G67']=1
    dataT1.loc[dataT1.G24>1, 'G24']=1
21
                                          59
                                               dataT1.loc[dataT1.G68>1,'G68']=1
    dataT1.loc[dataT1.G25>1, 'G25']=1
22
                                               dataT1.loc[dataT1.G69>1, 'G69']=1
                                          60
    dataT1.loc[dataT1.G26>1, 'G26']=1
23
                                               dataT1.loc[dataT1.G70>1,'G70']=1
                                          61
24
    dataT1.loc[dataT1.G27>1, 'G27']=1
                                          62
                                               dataT1.loc[dataT1.G71>1, 'G71']=1
25
    dataT1.loc[dataT1.G28>1,'G28']=1
                                               dataT1.loc[dataT1.G72>1,'G72']=1
26
    dataT1.loc[dataT1.G29>1, 'G29']=1
                                               dataT1.loc[dataT1.G73>1, 'G73']=1
                                          64
27
    dataT1.loc[dataT1.G30>1, 'G30']=1
                                               dataT1.loc[dataT1.G76>1,'G76']=1
28
    dataT1.loc[dataT1.G31>1,'G31']=1
                                          66
                                               dataT1.loc[dataT1.G77>1, 'G77']=1
    dataT1.loc[dataT1.G32>1,'G32']=1
29
                                          67
                                               dataT1.loc[dataT1.G79>1,'G79']=1
30
    dataT1.loc[dataT1.G33>1,'G33']=1
                                               dataT1.loc[dataT1.G80>1,'G80']=1
    dataT1.loc[dataT1.G34>1,'G34']=1
31
                                               dataT1.loc[dataT1.G82>1, 'G82']=1
                                          69
32
    dataT1.loc[dataT1.G35>1, 'G35']=1
                                          70
                                               dataT1.loc[dataT1.G83>1,'G83']=1
33
    dataT1.loc[dataT1.G36>1,'G36']=1
                                          71
                                               dataT1.loc[dataT1.G84>1,'G84']=1
34
    dataT1.loc[dataT1.G37>1,'G37']=1
                                          72
                                               dataT1.loc[dataT1.G85>1,'G85']=1
    dataT1.loc[dataT1.G40>1,'G40']=1
35
                                          73
                                               dataT1.loc[dataT1.G86>1,'G86']=1
36
    dataT1.loc[dataT1.G41>1,'G41']=1
                                          74
                                               dataT1.loc[dataT1.G87>1,'G87']=1
    dataT1.loc[dataT1.G42>1,'G42']=1
37
                                               dataT1.loc[dataT1.G88>1,'G88']=1
                                          75
    dataT1.loc[dataT1.G43>1,'G43']=1
38
                                          76
                                               dataT1.loc[dataT1.G89>1,'G89']=1
                                               dataT1.loc[dataT1.G90>1,'G90']=1
```

```
1 | plataT1.head()

2 | plataT1.head()

3 | plataT1.head()

3 | plataT1.head()

3 | plataT1.head()

3 | plataT1.head()

4 | pl
```

Encode do atributo classe poluido=1 limpo=0

## Separação do atributo classe

```
[22] 1  X = dataT1.drop('CLASSE', axis=1)
2  y = dataT1[['CLASSE']]
```

## Separação do atributo classe

```
[22] 1 X = dataT1.drop('CLASSE', axis=1)
2 y = dataT1[['CLASSE']]
```

Definidos e tratados os dados de entrada x e y do nosso conjunto de exemplos, podemos então separar os conjuntos de treinamento e teste.

## Modelo Sequencial

#### Declarando as Camadas

```
[74] 1 model = keras.Sequential(layers.Dense(161, activation='sigmoid', input_shape=[162]))
2 model.add(layers.Dense(1, activation='sigmoid'))
3 model.summary()

Model: "sequential_3"

Layer (type) Output Shape Param #
dense_6 (Dense) (None, 161) 26243

dense_7 (Dense) (None, 1) 162

Total params: 26,405
Trainable params: 26,405
Non-trainable params: 0
```

#### Compilando o Modelo

```
[75] 1 model.compile(loss='binary_crossentropy', metrics=['binary_accuracy'],)
```

#### Treinando o Modelo

```
history = model.fit(
[76]
     1
               X_train, y_train,
               validation_split=0.4,
               epochs=20,
               verbose=1,
   Epoch 1/20
4/4 [=====
Epoch 2/20
4/4 [=====
Epoch 3/20
                      ========] - 1s 87ms/step - loss: 0.6415 - binary_accuracy: 0.6604 - val_loss: nan - val_binary_accuracy: 0.7606
                                      Os 13ms/step - loss: 0.5391 - binary_accuracy: 0.7358 - val_loss: nan - val_binary_accuracy: 0.8310
                                 ==] - 0s 10ms/step - loss: 0.4870 - binary accuracy: 0.8491 - val loss: nan - val binary accuracy: 0.8310
   4/4 [=====
Epoch 4/20
   4/4 [=====
Epoch 5/20
4/4 [=====
Epoch 6/20
                        ========] - 0s 10ms/step - loss: 0.4458 - binary_accuracy: 0.9151 - val_loss: nan - val_binary_accuracy: 0.8451
                     =========] - 0s 10ms/step - loss: 0.4163 - binary_accuracy: 0.9057 - val_loss: nan - val_binary_accuracy: 0.8310
   4/4 [=====
Epoch 6/20
4/4 [=====
Epoch 7/20
4/4 [=====
Epoch 8/20
                                      0s 9ms/step - loss: 0.3915 - binary_accuracy: 0.9434 - val_loss: nan - val_binary_accuracy: 0.8451
                     ========] - 0s 9ms/step - loss: 0.3665 - binary_accuracy: 0.9434 - val_loss: nan - val_binary_accuracy: 0.8169
                       :========] - 0s 11ms/step - loss: 0.3480 - binary accuracy: 0.9151 - val loss: nan - val binary accuracy: 0.8451
   4/4 [=====
Epoch 9/20
   4/4 [=====
Epoch 10/20
            Epoch 10/20
4/4 [=======
Epoch 11/20
4/4 [======
Epoch 12/20
4/4 [======
Epoch 13/20
4/4 [=======
Epoch 14/20
                     ========] - 0s 9ms/step - loss: 0.3135 - binary_accuracy: 0.9528 - val_loss: nan - val_binary_accuracy: 0.8310
                       :=========] - 0s 10ms/step - loss: 0.2991 - binary_accuracy: 0.9434 - val_loss: nan - val_binary_accuracy: 0.8310
                                      0s 14ms/step - loss: 0.2839 - binary_accuracy: 0.9528 - val_loss: nan - val_binary_accuracy: 0.8310
                           Epoch 14/20
4/4 [======
Epoch 15/20
4/4 [======
Epoch 16/20
4/4 [======
Epoch 17/20
4/4 [======
Epoch 19/20
4/4 [======
Epoch 20/20
4/4 [======
                        ========] - 0s 12ms/step - loss: 0.2608 - binary_accuracy: 0.9528 - val_loss: nan - val_binary_accuracy: 0.8592
                      =======] - 0s 16ms/step - loss: 0.2487 - binary_accuracy: 0.9528 - val_loss: nan - val_binary_accuracy: 0.8310
                          =======] - 0s 13ms/step - loss: 0.2281 - binary_accuracy: 0.9623 - val_loss: nan - val_binary_accuracy: 0.8592
                         ========] - 0s 15ms/step - loss: 0.2199 - binary_accuracy: 0.9434 - val_loss: nan - val_binary_accuracy: 0.8592
```

## Curva de Apredizado

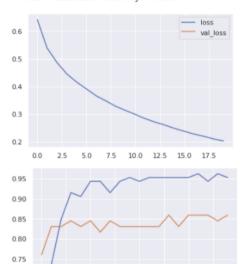
### [78] 1 display\_hist(history)

#### loss binary\_accuracy val\_loss val\_binary\_accuracy 0 0.641506 0.760563 0.660377 NaN 1 0.539056 0.735849 0.830986 2 0.487034 0.849057 0.830986 NaN 3 0.445777 0.915094 NaN 0.845070 4 0.416320 0.905660 NaN 0.830986

binary\_accuracy
val\_binary\_accuracy

5.0 7.5 10.0 12.5 15.0 17.5

Best Validation Loss: nan Best Validation Accuracy: 0.8592



0.70

0.0 2.5

#### Resultados

Podemos então avaliar os resultados do nosso modelo fazendo a predição do conjunto de teste selecionado anteriormente.

Aqui podemos empregar as métricas usuais do Scikit-Learn. A predição, tendo um único neurônio de saída com a função sigmóide (ou logística) devolve um único valor entre [0,1] e podemos entender esse valor como a chance de ser a classe 1.

### Conclusão

O objetivo de acuracidade de 0.8 foi atingido com o valor de 0.857, no entanto o dataset exigiu um validation\_split=0.4 ao invés de 0.3 do modelo original, por retornar NAN no Loss para valores abaixo de 0.4.